PULSARIDE SOLUTIONS

Deeptech · Sécurité & Intelligence Artificielle

Rue Henri Dunant, Pessac, France

Offre de stage — Data Science / Intelligence Artificielle

Assistant juridique et administratif souverain pour le citoyen : un système de recherche augmentée (RAG) sur le corpus de droit marocain

Entreprise	Pulsaride Solutions
Adresse	Rue Henri Dunant, Pessac, France
Encadrant	M. SALIHI Lyazid
Contact	contact@pulsaride.com
Domaine	Data Science · NLP · IA souveraine appliquée
Durée	4 mois
Profil	Étudiant(e) en Data Science / Data Analysis (Master / dernière année d'école d'ingénieur)

Contexte

Le Maroc a fait de l'intelligence artificielle souveraine une priorité nationale (feuille de route « Maroc IA 2030 », initiative « AI Made in Morocco », réseau des Instituts Al Jazari). L'un des principes directeurs de cette stratégie est la maîtrise de la donnée : une information sensible produite au Maroc doit pouvoir être traitée localement, sans dépendance critique vis-à-vis d'infrastructures étrangères.

Dans ce cadre, l'accès du citoyen à l'information juridique et administrative reste un point faible. Les textes (Code du travail, Code de la famille, Bulletin Officiel, codes sectoriels) sont publics, mais souvent inaccessibles : langage juridique dense, textes parfois disponibles uniquement en arabe, et absence d'outil fiable pour répondre à une question simple posée en langage courant. Les assistants génériques étrangers, eux, connaissent mal le droit marocain, peuvent inventer des références inexistantes, et font transiter les questions des citoyens hors du territoire.

Objectif du stage

Concevoir et évaluer un **assistant de recherche juridique souverain** fondé sur l'architecture RAG (*Retrieval-Augmented Generation*). Le citoyen pose une question en langage naturel ; le système recherche le passage pertinent dans le corpus juridique marocain, puis formule une réponse claire **en citant systématiquement la source officielle**. Le principe de fiabilité est central : le système s'appuie sur les textes réels et indique honnêtement lorsqu'il ne dispose pas de l'information, plutôt que d'inventer.

Exemple d'interaction visée

Citoyen : « J'ai droit à combien de jours de congé de maternité ? »

Assistant : « Selon l'article 152 du Code du travail (Loi 65-99), la salariée bénéficie d'un congé de maternité de 14 semaines. Le contrat de travail est suspendu, non rompu, pendant cette période.
Source : Code du travail, article 152.
Réponse fournie à titre informatif ; pour une situation particulière, consultez un professionnel. »

La dimension souveraine

Toute la chaîne reste marocaine et locale : les **données** sont le corpus juridique public marocain ; le **traitement** peut s'exécuter sur une infrastructure locale, sans envoyer la question du citoyen vers une API étrangère ; le **modèle** peut être un modèle open-source déployé localement. La question intime d'un citoyen sur ses droits ne quitte pas le territoire — ce qui incarne concrètement la « souveraineté du sens » défendue par la stratégie nationale.

Missions

Mission 1 — Constitution et préparation du corpus juridique (socle)

Collecter un corpus de textes juridiques marocains publics, le nettoyer et le découper intelligemment (par article / section) pour le rendre exploitable par la recherche sémantique. La qualité de ce découpage conditionne directement la qualité des réponses.

Mission 2 — Moteur de recherche sémantique et génération (cœur RAG)

Indexer le corpus, implémenter la recherche des passages pertinents à partir d'une question en langage naturel, puis générer une réponse claire et sourcée à l'aide d'un modèle de langage. Garantir l'ancrage dans les textes réels et la gestion explicite du « je ne sais pas ».

Mission 3 — Évaluation de la fiabilité

Construire un jeu de questions-réponses de référence et mesurer la précision du système : taux de réponses correctes, qualité des sources citées, détection des cas où le système doit s'abstenir. L'analyse honnête des limites fait partie intégrante du livrable.

Mission 4 — Extension multilingue — couche pivot (ambition, si le temps le permet)

Explorer une couche de normalisation linguistique : comprendre une question posée en darija, en arabe ou en français via une langue pivot, tout en conservant l'ancrage des réponses dans le texte officiel original. Règle directrice : on traduit pour comprendre et rechercher, jamais pour faire autorité — le texte de loi conserve sa valeur dans sa langue d'origine.

Périmètre et approche

Pour garantir la faisabilité en 4 mois, le sujet est volontairement borné. Le stage commence par un **périmètre juridique unique** (par exemple le droit du travail) et un système **monolingue solide** ; l'extension multilingue et l'élargissement à d'autres codes constituent les ambitions complémentaires. Un système qui fonctionne bien sur un domaine restreint est déjà une démonstration aboutie.

Le projet porte exclusivement sur la **recherche et la restitution d'information**. Il ne fournit pas de conseil juridique personnalisé et n'opère aucune décision automatisée à valeur légale ; chaque réponse renvoie à la source officielle et invite, le cas échéant, à consulter un professionnel.

Compétences mobilisées et développées

- Traitement automatique du langage naturel (NLP) et recherche sémantique (embeddings)
- Architecture RAG : indexation, récupération, génération augmentée, ancrage des sources
- Data engineering : nettoyage, structuration et découpage de corpus textuels
- Évaluation rigoureuse de modèles : métriques, jeux de référence, analyse des limites
- Sensibilisation à la souveraineté des données, à l'éthique de l'IA et au multilingue (arabe / darija / français)

Livrables attendus

- Un corpus juridique structuré, documenté et reproductible (périmètre de départ)
- Un prototype fonctionnel de l'assistant RAG (question → réponse sourcée)
- Un protocole d'évaluation et un rapport de performance honnête (forces et limites)
- Un rapport de stage et une présentation de soutenance

Critères de réussite

Le stage est réussi si l'assistant fournit, sur le périmètre choisi, des réponses correctes et systématiquement sourcées, sait s'abstenir lorsqu'il manque l'information, et si ses performances comme ses limites sont mesurées et analysées avec rigueur. La qualité de l'analyse des limites compte autant que la performance brute : un système fiable et honnête prime sur un système impressionnant mais opaque.

Candidature

Merci d'adresser CV et lettre de motivation à **contact@pulsaride.com**, à l'attention de M. SALIHI Lyazid (encadrant). Les candidat(e)s motivé(e)s par l'IA appliquée, le NLP et les enjeux de souveraineté numérique sont particulièrement encouragé(e)s à postuler.